## О распределении нетерминалов в деревьях вывода стохастической КС-грамматики вида «цепочки»

## И. М. Мартынов

murbidodrus@gmail.com

ННГУ им. Н. И. Лобачевского, Нижний Новгород

В работе исследуются вероятностные свойства деревьев вывода стохастической КС-грамматики специального вида. Рассматривается случай, когда матрица первых моментов A грамматики разложима и имеет перронов корень равный 1. Целью работы ялвляется исследование распределения нетерминальных символов в деревьях вывода высоты t, при  $t \to \infty$ .

Стохастической КС-грамматикой называется система  $G=\langle V_N,V_N,R,s\rangle$ , где  $V_T$  и  $V_N$  — конечные алфавиты терминальных и нетерминальных символов соответственно,  $s\in V_N$  — аксиома,  $R=\cup_{i=1}^k R_i$ , где k — мощность алфавита  $V_N$  и  $R_i$  — множество правил с одинкаовой левой частью вида

$$r_{ij}: A_i \xrightarrow{p_{ij}} \beta_{ij}, \ j = 1, 2, \dots, n,$$

где  $A_i \in V_N, \ \beta_{ij} \in (V_T \cup V_N)^*$  и  $p_{ij}$  — вероятность применения правила  $r_{ij},$  причем  $0 < p_{ij} \leqslant 1$  и  $\sum_{j=1}^{n_i} p_{ij} = 1$ .

Применение правила грамматики к слову состоит в замене вхождения нетерминала из левой части правила на слово, стоящее в его правой части.

Каждому слову  $\alpha$  КС-языка соответствует последовательность правил грамматики (вывод), с помощью которой  $\alpha$  выводится из аксиомы s. Выводу слова соответствует дерево вывода, вероятность которого определяется как произведение вероятностей правил, образующих вывод.

По стохастической КС-грамматике строится матрица A первых моментов. Для неё элемент  $a_j^i$  определяется как  $\sum_{l=1}^{n_i} p_{il} s_{il}^j$ , где величина  $s_{il}^j$  равна числу нетерминальных символов  $A_j$  в правой части правила  $r_{il}$ . Перронов корень матрицы A обозначим через r.

Введём отношение на множестве нетерминалов. Будем обозначать  $A_i \to A_j$ , если в грамматике существует правило вида  $A_i \xrightarrow{p_{il}} \alpha_1 A_j \alpha_2$ , где  $\alpha_1, \alpha_2 \in (V_T \cup V_N)^*$ . Рефлексивное транзитивное замыкание отношения  $\to$  обозначим  $\to_*$ .

Классом нетерминалов назовём максимальное по включению подмножество  $K \in V_N$  такое, что  $A_i \to_* A_j$  для любых  $A_i, A_j \in K$ . Отношение  $\to_*$  на множестве нетерминалов порождает отношение на множестве их классов. Будем обозначать  $K_1 \prec K_2$ , если существуют  $A_1 \in K_1$  и  $A_2 \in K_2$ , такие, что  $A_1 \to A_2$ . Рефлексивное транзитивное замыкание отношения  $\prec$  обозначим через  $\prec_*$ .

Пусть  $\mathcal{K} = \{K_1, K_2, \dots, K_m\}$  — множество классов нетерминалов грамматики,  $m \geqslant 2$ . Будем говорить, что грамматика имеет вид «цепочки», если  $K_i \prec K_j$  тогда и только тогда, когда i+1=j.

Матрица первых моментов грамматики вида «цепочки» имеет вид:

$$A = \begin{pmatrix} A_{11} & A_{12} & 0 & \cdots & 0 & 0 \\ 0 & A_{22} & A_{23} & \cdots & 0 & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & 0 & \cdots & A_{n-1,n-1} & A_{n-1,n} \\ 0 & 0 & 0 & \cdots & 0 & A_{n,n} \end{pmatrix}$$

Один класс нетерминалов представлен в матрице множеством подряд идущих строк и соответствующим множеством столбцов с теми же номерами. Для класса  $K_i$  квадратная подматрица, образованная соответствующими строками и столбцами, обозначается через  $A_{ii}$ . Подматрица  $A_{ij}$  ( $i \neq j$ ) является нулевой, если  $K_i \not\prec K_j$ . Блоки, расположенные ниже главной диагонали, нулевые в силу упорядоченности классов.

Для каждого класса  $K_i$  матрица  $A_{ii}$  неразложима. Без ограничения общности будем считать, что она строго положительна и непериодична. Обозначим через  $r_i$  перронов корень матрицы  $A_{ii}$ . Для неразложимой матрицы перронов корень является вещественным и простым [1]. Очевидно,  $r = \max\{r_i\}$ .

Пусть  $J=\{i_1,i_2,\ldots,i_l\}$  — множество всех номеров  $i_j$  классов, для которых  $r_{ij}=1$ . Классы  $K_l$  такие, что  $l\in J$ , будем называть критическими. Также обозначим через  $q_l$  число критических классов среди подцепочки  $K_l,K_{l+1},\ldots,K_m$ . Тогда верна следующая теорема.

**Теорема 1.** Математические ожидания  $M_i(t)$  числа нетерминалов  $A_i$  в деревьях вывода высоты t, порождённых стохастической КС-грамматикой вида «цепочки», при  $t \to \infty$  удовлетворяют условию:

$$M_i(t) \sim d_i \cdot t^{\left(\frac{1}{2}\right)^{q_l^*-1}},$$

где  $q_l^* = q_l - 1$  при  $l \in J$ , и  $q_l^* = q_l$  при  $l \notin J$ ,  $A_i \in K_l$ , и  $d_i$  — некоторые константы.

Обозначим через  $q_i(t)$  число нетерминалов  $A_i$  в случайном дереве высоты t, порождённом грамматикой. Рассмотрим произвольную пару нетерминалов  $A_i$  и  $A_j$  таких, что математические ожидания  $M_i(t)$  и  $M_j(t)$  имеют один порядок по t, при  $t \to \infty$ . Верна следующая теорема.

**Теорема 2.** Для любых двух нетерминалов  $A_i \in K_l$ ,  $A_j \in K_s$  таких, что  $q_l^* = q_s^*$ , при  $t \to \infty$  выполняется условие:

$$D\left(\frac{q_i(t)}{q_i(t)} - \frac{d_i}{d_i}\right) \to 0,$$

где  $q_i(t), q_j(t)$  — количество нетерминалов  $A_i, A_j$  соответственно в деревьях высоты  $t, d_i$  и  $d_j$  — некоторые константы.

Другими словами, при  $t \to \infty$  соотношение частот между двумя нетерминалами, имеющими одинаковую асимптотику математических ожиданий, становится всё ближе к фиксированному значению.

## Литература

[1] Гантмахер  $\Phi$ . Р. Теория матриц. 5-е изд. — М.:  $\Phi$ ИЗМАТЛИТ, 2010.-560 с.